

学习笔记

专题一：提交内容

1.数据清洗和特征处理方法；

本项目采用了删除特征，根据特点填补缺失值，无量纲化的标准化，创造新特征的方法。具体描述如下：

- 删除特征：训练集中我删除了"PassengerId"（无效），"Name"（姓名中除了可以看出性别、年龄这些已知信息外，还可以反映出社会地位以及是否已婚等信息，但时间紧，且处理Name有点复杂，所以暂时舍弃，之后优化会加上），"Survived"（单独处理label以防止数据泄露），"Ticket"（编号可能隐藏一些信息，比如编号小的可能地位高实力强，但偶然性太大，故舍去），"Cabin"（客舱号缺失太多，且因为人员活动，如果补全并采用可能对模型造成误导，误差大）
- 根据特点填补缺失值：数值型采用中位数填补，如Age,Fare.(不用均值是因为均值受异常值的影响较大)。类别型采用众数填补（有多个众数时选择第一个）
- 无量纲化的标准化：一般对处理后的数据范围没有太严格的要求都选择标准化，而非归一化（标准化受极端异常值的影响较小）（这里有个疑惑，我尝试了筛选标准化之后的数据，显示有超过了【-10, 10】的区间的，但打印出来的部分序列数值都很小（没有异常数据））
- 创造新特征：利用SibSp, Parch合并成为了新的特征FamilySize, IsAlone这些数据可能反馈出，乘客可能因等待生存几率下降，或因互助让生存几率上升。（有了FamilySize，还要创造IsAlone是因为，模型不能清晰认识到独行的影响，FamilySize的1、2、3、4对模型来说是等差的，但其实1和2有着天差地别的差距，所以创造了IsAlone判断是否独行）
- 补充：本题没有异常数据，如果有，可采用如下方法，将异常值归为NaN，再和缺失值一起处理。（按理说如果要删异常值，应该要交叉验证一下(防止出现主观臆断)，并且记录一下哪些数据被删了，但是暂时还没学会）

```
bad = (data['age'] < 0) | (data['age'] > 120)
data.loc[bad, 'age'] = np.nan
```

2.模型结构、损失函数、优化器及主要超参数

- 模型结构：利用nn.Module构造了一个深度学习的网络，采用了线性函数和激活函数结合，利用Dropout进行正则化（优化时还可以视情况加入L2正则化，还可以把一些删去的特征加上，并用L1正则化进行间接选择），一共有两个隐藏层（在设置模型时是没有设置输入层的）。实操时模型采用了先预测，再算Loss，再反向传播、结合Adam改参数（记得清除之前的梯度），训练完后关梯度，算测试集准确率
- 损失函数：是利用torch中的nn.CrossEntropyLoss（交叉熵损失），适合分类任务，可以在[PyTorch 官方CrossEntropyLoss 文档] <https://pytorch.org/docs/stable/generated/torch.nn.CrossEntropyLoss.html> 中查看细节（太多了，记不住）
- 优化器：运用Adam优化器（Adam 优化器是一个能为每个参数调整学习率，并且可以根据梯度进行动态调整的系数优化器。他结合了Momentum和RMSProp的优点）
- 主要超参数

超参数	取值	出处
隐藏层神经元数 h1 / h2	32 / 16	model.py
Dropout 率 p	0.32	model.py
学习率 lr	0.1	train.py
训练轮数 epochs	200	train.py
测试集比例	0.2	data.py TEST_RATE
随机种子	42	data.py / train.py
优化器	Adam	train.py

3.数据划分方式、随机种子和实验配置

- 数据划分方式:先将幸存和没幸存分开，打乱后，按训练集、测试集比例将幸存和没幸存划分，再相应地拼装在一起，最后再打乱一次。
- 随机种子：设定了固定种子——42，便于调试，消除部分偶然性
- 实验配置：(部分由ai生成)
 - 1. 运行环境

项	值
操作系统	Windows 11
解释器	pycharm
Python	3.14.7
PyTorch	2.11.0+cu128
NumPy / pandas	2.5.2 / 3.0.5
matplotlib	3.11.1
实际计算设备	CPU （代码中未调用 .cuda()）

2. 产出文件

文件	说明
model/titanic.pth	模型权重
Training_loss_curve.png	训练损失曲线
Test_accuracy_curve.png	测试准确率曲线
titanic学习笔记.ipynb	学习笔记

3. 实跑结果（2026-09-23）

指标	数值
首轮 loss	0.6234
末轮 loss	0.3547
最终测试准确率（第 200 轮）	0.8305
全程最高测试准确率	0.8701
全猜遇难基线	0.6158
预测示例（一等舱 25 岁女性）	预测幸存，概率为 0.9999

4.训练过程中遇到的问题及解决方法

内容有些多，单独列了一个专题（见专题2）

5.测试集准确率、实验结果分析和心得体会

- 测试集准确率：可以达到83.05%
- 实验结果分析:损失有较明显的下降，但是精确度在后期也下降了（依然高于盲猜）。对于预测，有时他会给出概率为1的错误预测。可能是过拟合，或是噪音等问题。
- 心得体会：心得体会不多，但也单列了一个专题（见专题3）

专题二：训练过程中遇到的问题及解决方法

说明1：部分由ai生成，再由本人修改
说明2：这里只是部分，更多在源代码中有注释

问题	答案
df: {__getitem__, copy}	不是可执行代码，是"能力清单"：能 df['列'] 取值、能 .copy()
torch.tensor是什么	相当于 np.array，但能上 GPU、能自动求梯度；是"预处理结果 → 网络"的桥
dtype vs astype 区别	dtype 是 属性 （查现在啥类型）；astype 是 方法 （返回改类型后的新数组）
np.where(...)[0] 的 [0]	np.where 返回"元组包数组"，[0] 把真正的下标数组剥出来，才能 [:n] 切片
FEATURE_ORDER 为何能固定顺序	list 有序 + feats[ORDER] 强制重排。网络只认"第几个输入口"，错位会 安静地算错
函数里的变量怎么搬出去	局部变量函数结束即销毁。正规做法： 一律用 return 传 （可返多个值/字典/对象）
环境/脚本定位	os.path.dirname(os.path.abspath(__file__)) 拿脚本所在目录

2. 报错表（学长，放下屠刀，这个是ai根据我问他的问题生成的（所以也不太全），我修改成了我能看懂的样子，但我背不到啊~~~）

报错	原因	改法
KeyError: ['PassengerId'] not found	同一列被 drop 两次	只留一个 drop
KeyError: ['FamilySize'] not in index	FamilySize 是新创造的特征，却在创造前调用	改顺序
AttributeError: 'tuple' object has no attribute 'drop'	return self, df 打成元组，破坏赋值链	删掉 self
TypeError: int() ... not DataFrame	a.split(df) 多传的 df 被当 test_size	split 再接收一个 df 形参
TypeError: module() takes at most 2 arguments (3 given)	class Net(nn) —— nn 是模块不能继承	class Net(nn.Module)
TypeError: empty(): argument 'size' failed...	Net(nn.Module) 把类当维数传进去了	传整数 Net(ncol)
KeyError: ['FamilySize', 'Sex_male'] not in index	用原始 df 取新的特征	X = df2[ORDER].values.astype('float32')
IndexError: Target 1 is out of bounds	CrossEntropyLoss 要 2, 给的 1	模型输出改为2
Cannot assign modules before Module.__init__()	漏了 super().__init__()	__init__ 第一行补齐
ImportError: cannot import name 'draw'	函数的引用成环了	改成单向，main控制全部
mat1 and mat2 shapes cannot be multiplied (5x12 and 13x32)	喂了 12 维	特征按 ORDER 补齐 13 维
all the input array dimensions must match	concatenate 时拼不上 (维度问题)	竖接看列数、横接看行数
'numpy.ndarray' object is not callable	.values() 多加了括号	.values 无括号
OMP: Error #15	torch 与 numpy 各带一份 OpenMP	main.py 首行 (import torch 之前) 设 os.environ['KMP_DUPLICATE_LIB_OK']='TRUE'

专题三：心得体会

关于知识的很多都在前面或是源代码里，这里就唠唠嗑了。经过多天的奋战，代码终于能跑通了，都是缺哪补哪，所以看着不太美观。也是学到了很多，包括以前用的不熟的python更熟了（虽然现在也经常漏这漏那），pytorch,numpy,pandas,matplotlib也零零散散的掌握了好多（不太系统就是了），反正还是挺有成就感的，虽

然它现在是危墙，以后学的久了肯定能牢固（应该吧）。心得我就少写点了，节约学长时间（~~绝对不是因为我手打了两万字已经累了~~）

专题四：优化方向

1. 处理Name特征
2. 视情况加一些方法：早停，L1正则（再给他几个舍弃的特征，让他帮我选）
3. 加入对GPU的选择使用
4. 改善精确度和损失
5. 将数据处理分为dataset和dataloader
6. 多引进几个验证模型学习程度的图像，参数（混淆矩阵，recall等等）
7.（有些忘了）